



Progetto di Machine Learning 2025/2026

Gabriel Pesce (899638)
Francesca Tentori (899835)
Matteo Ronchi (899659)



Obiettivo del Progetto

Analisi delle prestazioni di **due modelli** di Machine Learning tramite l'addestramento su un dataset scelto.

Dataset: <https://archive.ics.uci.edu/dataset/94/spambase>



Caratteristiche del dataset

Nome	Num. Feature	Num. Istanze
<i>Spambase</i>	57	4601

- Le istanze nel dataset rappresentano le email.
- L'**obiettivo** del dataset è **stabilire se la email è spam oppure no**.
- Variabile target: **Class**→ **Variabile binaria**, indica se la mail è Spam oppure no.
- Tutte le feature sono **numeriche** (rappresentate da numeri).
- Il dataset non presenta valori nulli.




Tipologie di feature

1. **word_freq_<word>**: percentuale di occorrenza della parola <word>.
2. **char_freq_<symbol>**: percentuale di occorrenza del carattere <symbol>.
3. **capital_run_length_average**: lunghezza media ininterrotta delle sequenze di lettere maiuscole nell'e-mail.
4. **capital_run_length_longest**: lunghezza della sequenza ininterrotta di lettere maiuscole più lunga individuata.
5. **capital_run_length_total**: somma totale di tutte le lettere maiuscole presenti nell'intero messaggio.

Caratteristiche del dataset

Distribuzione della variabile target: Class




Il dataset risulta mediamente sbilanciato

61% Email 'Non spam'

39% Email 'Spam'


Box plot - Analisi del potere discriminante delle feature



Sono stati analizzati i Box Plot per identificare le feature più discriminati del dataset.

Maggiore è il valore di s , più le feature sono discriminati.

$$s_j = \frac{|\text{med}_{\text{spam}}(x_j) - \text{med}_{\text{non-spam}}(x_j)|}{\sigma_j + \epsilon}$$




Pair Plot - Analisi delle relazioni tra le feature più discriminanti

Sono stati effettuati i Pair Plot sulle feature più discriminate per capire il tipo di relazione tra esse, in modo da scegliere il coefficiente corretto per valutare le correlazioni.

Essendo che le variabili non hanno relazione lineare, abbiamo utilizzato Spearman.

Matrice di Correlazione completa (Spearman)




Matrice di correlazione completa

Le celle con il colore più scuro indicano un'alta correlazione tra le variabili.

Il coefficiente usato è stato quello di **Spearman**, in quanto, lavorando sui ranghi anzichè su valori assoluti, è in grado di gestire meglio la forte variazione dei valori per ciascuna istanza.

Avendo un totale di 57 feature, risulta difficile vedere esattamente il valore delle correlazioni. Per questo motivo, ci siamo concentrati sulla parte centrale della matrice e sull'angolo in basso a destra, dove sono più presenti segni di elevata correlazione.

Matrice di Correlazione - Blocco Centrale (Spearman)




Matrice di correlazione centrale

La massima correlazione presente è tra **word_freq_415** e **word_freq_857** (0.96).

Altri casi di altra correlazione sono:

- **word_freq_hp** e **word_freq_hpl** (0.76)
- **word_freq_650** e **word_freq_85** (0.72)
- **word_freq_telnet** e **word_freq_415** (0.71)
- **word_freq_telnet** e **word_freq_85** (0.66)

Matrice di Correlazione - Blocco Angolare (Spearman)





Matrice di correlazione angolare

Le tre variabili sono molto correlate tra loro, data la loro ridondanza, nella fase di preprocessing ne verrà mantenuta solo una in base alla correlazione con il target.

- `capital_run_length_average` e `capital_run_length_longest` (0.86)
- `capital_run_length_longest` e `capital_run_length_total` (0.86)

Distribuzione delle feature più correlate con il target



Analisi del p-value



Il ***p-value*** misura la probabilità che la correlazione tra le feature e il target sia puramente casuale.

Usando una soglia di significatività $\alpha=0.05$, i casi più rilevanti sono stati:

- ***word_freq_parts*** con un p-value = 0.8640
- ***word_freq_table*** con un p-value = 0.1242
- ***word_freq_direct*** con un p-value = 0.0564

Dato che $p\text{-value} > \alpha \rightarrow$ La feature non ha legame statistico con la feature, bensì la correlazione è puramente casuale.



Fase di Preprocessing

Rimozione della variabili altamente correlate

Sono state rimosse le variabili altamente correlate tra le feature. In questo modo, i modelli che lavorano mediante le distanze non subiscono un degradamento delle prestazioni.

1. Le variabili *capital_run_length_average* e *capital_run_length_total* sono state rimosse in quanto presentavano una correlazione reciproca elevata con *capital_run_length_longest*.

Quest'ultima è stata mantenuta in quanto è più correlata col target.

- ❑ *capital_run_length_longest*: $r_{\text{target}} = 0.515$
- ❑ *capital_run_length_average*: $r_{\text{target}} = 0.488$
- ❑ *capital_run_length_total*: $r_{\text{target}} = 0.444$



Fase di Preprocessing

Rimozione della variabili altamente correlate

Le restanti feature rimosse sono:

- ❑ *word_freq_table*
- ❑ *word_freq_hpl*
- ❑ *word_freq_parts*
- ❑ *word_freq_direct*
- ❑ *word_freq_415*




Fase di Modellazione

Per la fase di Modellazione sono state effettuate le seguenti operazioni:

1. **Hold-Out Validation:** divisione del dataset in set di training e set di test. La proporzione usata per i due set è 80/20. Lo split segue un approccio **stratificato**, cioè che per entrambi i set viene mantenuta la stessa proporzione di entrambi le classi target.
2. **Standardizzazione dei dati:** dato che la SVM lavora mediante le distanze e sono sensibili alla scala dei dati, le feature sono state standardizzate in modo da uniformare valori molto differenti tra loro.

Modello di Baseline



È stato introdotto un modello baseline in grado di fornire un punto di riferimento con cui confrontare le performance dei modelli analizzati.

Questo modello “Dummy” predilige sempre la classe maggioritaria.

Modelli selezionati



Decision Tree

- **criterion: "Gini"** → Funzione che misura la qualità dello split.
- **max_depth: 18** → La profondità massima dell'albero.
- **class_weight: "balanced"** → Gestisce lo sbilanciamento del dataset.
- **min_samples_split: 2** → Numero minimo di campioni che un nodo deve avere per poter essere ulteriormente diviso.

Support Vector Machine

- **C: 10** → Controlla il compromesso tra $\max\{\text{margine}\}$ e $\min\{\text{errori di classificazione}\}$.
- **kernel: "linear"** → Funzione che stabilisce come organizzare i dati nello spazio.
- **class_weight: "balanced"** → Gestisce lo sbilanciamento del dataset.
- **probability: True** → Calcola la probabilità con cui il modello assegna la classe ai dati.

Scelta dei parametri 1



Per ottenere dei risultati ottimali mantenendo un moderato tempo di computazione, sono stati testati diversi valori per i parametri selezionati.

La funzione che ha permesso di stabilire quali fossero i migliori parametri è chiamata `GridSearchCV`.

`estimator`: Il modello su cui fare la ricerca.

`param_grid`: Dizionario con i parametri da esplorare e i valori da provare.

`cv`: Numero di fold per la cross-validation (es. `cv=5` divide il training set in 5 parti, allena su 4 e valuta sulla quinta).

`scoring`: Metrica usata per confrontare le combinazioni e scegliere la migliore (es. Accuracy).

`n_jobs`: Quanti core del processore usare in parallelo. (es. `n_jobs=-1` usa tutti i core disponibili).

Scelta dei parametri 2



Support Vector Machine

Sono stati testati 5 valori del parametro C: [0.01, 0.1, 1, 10, 100]


Secondo la GridSearchCV, il valore che ha restituito l'accuracy maggiore (0.93) è per **C=10**.

Decision Tree

Sono stati testati 20 valori del parametro max_depth: [1, 2, ..., 20]

Secondo la GridSearchCV, il valore che ha restituito l'accuracy maggiore (0.92) è per **max_depth=18**.


Risultati del Decision Tree



Classe / Metrica	Precision	Recall	F1-Score	Support
0 (Not Spam)	0.92	0.94	0.93	558
1 (Spam)	0.90	0.88	0.89	363
Accuracy			0.91	921
Macro Avg	0.91	0.91	0.91	921
Weighted Avg	0.91	0.91	0.91	921

Tempo di training impiegato: $\approx 0.1s$


Risultati della SVM




Classe / Metrica	Precision	Recall	F1-Score	Support
0 (Not Spam)	0.94	0.94	0.94	558
1 (Spam)	0.91	0.90	0.90	363
Accuracy			0.93	921
Macro Avg	0.92	0.92	0.92	921
Weighted Avg	0.93	0.93	0.93	921

Tempo di training impiegato: **≈13s**

Trade off Prestazioni/Tempi



Nota: per ogni esecuzione, i tempi di computazione cambiano, ma in media la SVM impiega molto più tempo durante il training.



Curva ROC

La **Curva di Roc** serve a valutare l'accuratezza e l'affidabilità di un sistema di classificazione binaria al variare della soglia di decisione, permettendo di bilanciare sensibilità e specificità.



Conclusioni

La SVM si conferma come miglior modello per questo dataset. Tuttavia, l'Albero di Decisione ha fornito ottimi risultati senza l'utilizzo di standardizzazione.

Modello	Accuracy	Precision	Recall	F1-Score
Baseline	0.61	0.37	0.61	0.46
Decision Tree	0.91	0.91	0.91	0.91
SVM	0.93	0.93	0.93	0.93