



UNIVERSITÀ DEGLI STUDI DI MILANO - BICOCCA

Scuola di Scienze

Dipartimento di Informatica, Sistemistica e Comunicazione

Corso di laurea Magistrale in Informatica

Machine Learning

Report di progetto

Pesce Gabriel - 899638
Ronchi Matteo - 899659
Tentori Francesca - 899835

Anno Accademico 2025 - 2026

Indice

1	Descrizione del dominio e degli obiettivi	3
1.1	Scelta del dataset	3
1.2	Obiettivo del progetto	3
1.3	Attività di progetto	3
2	Scelta del dataset, ipotesi e assunzioni	4
2.1	Caratteristiche del dataset	4
2.2	Azioni effettuate sul dataset	6
3	Analisi esplorativa	7
3.1	Analisi e distribuzione della classe target	7
3.2	Analisi del potere discriminante delle feature	8
3.3	Analisi delle relazioni tra le feature più discriminanti	8
3.4	Matrice di correlazione di Spearman	9
3.5	Analisi del P-value	13
4	Descrizione dei Modelli utilizzati	14
4.1	Modello Baseline	14
4.2	Decision tree	14
4.3	SVM	14
5	Descrizione della campagna sperimentale	16
5.1	Albero Decisionale	16
5.2	Support Vector Machine	17
6	Analisi dei risultati	18
6.1	Definizione delle metriche	18
6.2	Risultati dei modelli	19
6.2.1	Modello di Baseline	19
6.2.2	Decision Tree	19
6.2.3	Support Vector Machine (SVM)	20
6.3	Curva di ROC	21
6.4	Tempo di training	22
6.5	Confronto col modello baseline	22
7	Conclusioni	23

Capitolo 1

Descrizione del dominio e degli obiettivi

1.1 Scelta del dataset

Il progetto si colloca nel dominio del Machine Learning supervisionato e affronta un problema di classificazione nel contesto della sicurezza informatica e del filtraggio automatico delle comunicazioni digitali, in particolare per l'identificazione di e-mail di spam. È stato utilizzato il dataset **SpamBase**, disponibile presso l'UCI Machine Learning Repository¹

1.2 Obiettivo del progetto

Il progetto affronta un problema di classificazione binaria nel dominio dell'analisi quantitativa del testo, con lo scopo di distinguere automaticamente le comunicazioni legittime da quelle indesiderate valutando le frequenze di specifiche parole chiave e caratteri speciali.

1.3 Attività di progetto

Il lavoro svolto è stato suddiviso nelle seguenti attività:

- **Analisi Esplorativa dei Dati:** Indagare la distribuzione delle feature e identificare eventuali correlazioni o multicollinearità tra le variabili all'interno del dataset.
- **Ottimizzazione e Pre-processing:** Rimozione delle feature ridondanti e applicazione tecniche di standardizzazione per migliorare la robustezza dei modelli.
- **Sviluppo di Modelli Predittivi:** Implementare algoritmi di classificazione (Decision Tree e Support Vector Machine).
- **Valutazione Comparativa:** Confrontare le performance dei modelli attraverso matrici di confusione, curve ROC e tempo di training, al fine di individuare il modello più affidabile per l'impiego in un sistema reale di posta elettronica per il blocco preventivo dello spam.

¹Il dataset è disponibile al seguente link: <https://archive.ics.uci.edu/dataset/94/spambase>.

Capitolo 2

Scelta del dataset, ipotesi e assunzioni

2.1 Caratteristiche del dataset

Il dataset originale presenta **57 feature numeriche continue**, ovvero feature che possono assumere infiniti valori all'interno di un intervallo di misurazione, con un totale di **4601 istanze**.

Di seguito vengono descritte tutte le feature del dataset.

1. **word_freq_make:** percentuale di occorrenza della parola "make" nel testo.
2. **word_freq_address:** percentuale di occorrenza della parola "address" nel testo.
3. **word_freq_all:** percentuale di occorrenza della parola "all" nel testo.
4. **word_freq_3d:** percentuale di occorrenza del termine "3d" nel testo.
5. **word_freq_our:** percentuale di occorrenza della parola "our" nel testo.
6. **word_freq_over:** percentuale di occorrenza della parola "over" nel testo.
7. **word_freq_remove:** percentuale di occorrenza della parola "remove" nel testo.
8. **word_freq_internet:** percentuale di occorrenza della parola "internet" nel testo.
9. **word_freq_order:** percentuale di occorrenza della parola "order" nel testo.
10. **word_freq_mail:** percentuale di occorrenza della parola "mail" nel testo.
11. **word_freq_receive:** percentuale di occorrenza della parola "receive" nel testo.
12. **word_freq_will:** percentuale di occorrenza della parola "will" nel testo.
13. **word_freq_people:** percentuale di occorrenza della parola "people" nel testo.
14. **word_freq_report:** percentuale di occorrenza della parola "report" nel testo.
15. **word_freq_addresses:** percentuale di occorrenza della parola "addresses" nel testo.
16. **word_freq_free:** percentuale di occorrenza della parola "free" nel testo.
17. **word_freq_business:** percentuale di occorrenza della parola "business" nel testo.
18. **word_freq_email:** percentuale di occorrenza della parola "email" nel testo.
19. **word_freq_you:** percentuale di occorrenza della parola "you" nel testo.
20. **word_freq_credit:** percentuale di occorrenza della parola "credit" nel testo.
21. **word_freq_your:** percentuale di occorrenza della parola "your" nel testo.
22. **word_freq_font:** percentuale di occorrenza della parola "font" nel testo.
23. **word_freq_000:** percentuale di occorrenza del termine "000" nel testo.
24. **word_freq_money:** percentuale di occorrenza della parola "money" nel testo.

25. **word_freq_hp**: percentuale di occorrenza della parola "hp" nel testo.
26. **word_freq_hpl**: percentuale di occorrenza della parola "hpl" nel testo.
27. **word_freq_george**: percentuale di occorrenza della parola "george" nel testo.
28. **word_freq_650**: percentuale di occorrenza del termine "650" nel testo.
29. **word_freq_lab**: percentuale di occorrenza della parola "lab" nel testo.
30. **word_freq_labs**: percentuale di occorrenza della parola "labs" nel testo.
31. **word_freq_telnet**: percentuale di occorrenza della parola "telnet" nel testo.
32. **word_freq_857**: percentuale di occorrenza del termine "857" nel testo.
33. **word_freq_data**: percentuale di occorrenza della parola "data" nel testo.
34. **word_freq_415**: percentuale di occorrenza del termine "415" nel testo.
35. **word_freq_85**: percentuale di occorrenza del termine "85" nel testo.
36. **word_freq_technology**: percentuale di occorrenza della parola "technology" nel testo.
37. **word_freq_1999**: percentuale di occorrenza del termine "1999" nel testo.
38. **word_freq_parts**: percentuale di occorrenza della parola "parts" nel testo.
39. **word_freq_pm**: percentuale di occorrenza della parola "pm" nel testo.
40. **word_freq_direct**: percentuale di occorrenza della parola "direct" nel testo.
41. **word_freq_cs**: percentuale di occorrenza della parola "cs" nel testo.
42. **word_freq_meeting**: percentuale di occorrenza della parola "meeting" nel testo.
43. **word_freq_original**: percentuale di occorrenza della parola "original" nel testo.
44. **word_freq_project**: percentuale di occorrenza della parola "project" nel testo.
45. **word_freq_re**: percentuale di occorrenza della parola "re" nel testo.
46. **word_freq_edu**: percentuale di occorrenza della parola "edu" nel testo.
47. **word_freq_table**: percentuale di occorrenza della parola "table" nel testo.
48. **word_freq_conference**: percentuale di occorrenza della parola "conference" nel testo.
49. **char_freq_;**: percentuale di occorrenza del carattere speciale punto e virgola.
50. **char_freq_(**: percentuale di occorrenza della parentesi tonda aperta.
51. **char_freq_[:**: percentuale di occorrenza della parentesi quadra aperta.
52. **char_freq_!**: percentuale di occorrenza del punto esclamativo.
53. **char_freq_\$**: percentuale di occorrenza del simbolo del dollaro.
54. **char_freq_#**: percentuale di occorrenza del simbolo cancelletto.
55. **capital_run_length_average**: lunghezza media ininterrotta delle sequenze di lettere maiuscole nell'e-mail.
56. **capital_run_length_longest**: lunghezza della sequenza ininterrotta di lettere maiuscole più lunga individuata.
57. **capital_run_length_total**: somma totale di tutte le lettere maiuscole presenti nell'intero messaggio.

La variabile target è *Class* e può restituire due valori:

$$Class = 1 = Spam \parallel Class = 0 = Not Spam$$

2.2 Azioni effettuate sul dataset

Durante la fase di preparazione, sono state effettuate le seguenti scelte metodologiche:

- **Feature Selection:** È stata analizzata la matrice di correlazione di Spearman per individuare fenomeni di **multicollinearità** e il p-value. Sono state rimosse 7 feature ridondanti o poco informative, tra cui *word_freq_table*, *word_freq_hpl*, *word_freq_parts*, *word_freq_direct*, *word_freq_415*, *capital_run_length_average* e *capital_run_length_total*; riducendo così la ridondanza informativa, particolarmente critica per il Support Vector Machine (SVM).
- **Suddivisione del dataset:** Il dataset è stato suddiviso mediante tecnica di **Hold-Out Validation** in due set, 80% per il set di training e il 20% per il set di testing. La tecnica è utile per addestrare i modelli sul training set e valutarne le performance sui test set mai visti prima.
- **Standardizzazione:** Per il modello basato sul calcolo della distanza euclidea (SVM) è stata applicata la tecnica dello *StandardScaler*. Le feature sono state trasformate per avere media $\mu = 0$ e varianza $\sigma^2 = 1$, evitando che variabili con ordini di grandezza superiori influenzino in modo sproporzionato l'addestramento dei modelli.
- **Prevenzione del Data Leakage:** Per garantire l'integrità del test set e la capacità di generalizzazione, i parametri della standardizzazione sono stati calcolati esclusivamente sul set di training e successivamente applicati al set di test, in modo tale da garantire che rimanesse un campione mai osservato dal modello prima dell'effettiva predizione.

Capitolo 3

Analisi esplorativa

La fase iniziale dello studio si è concentrata sull'esplorazione del dataset per comprenderne le proporzioni interne e le relazioni tra le diverse feature. L'analisi ha mostrato che all'interno del dataset non sono presenti valori nulli.

3.1 Analisi e distribuzione della classe target

Durante l'analisi della distribuzione della classe target è stato rivelato un leggero sbilanciamento delle classi: circa il 61% delle istanze appartiene alla classe delle email non spam, mentre il restante 39% alle email spam. Questa asimmetria è stata considerata in fase di partizionamento dei dati (tramite stratificazione) per garantire che sia il training set sia il test set mantenessero la stessa distribuzione delle classi presente nell'intero dataset.

Distribuzione della variabile target: Class




Figura 3.1: Distribuzione delle classi nel dataset

3.2 Analisi del potere discriminante delle feature

Per valutare il potere discriminante di ciascuna feature rispetto alla variabile target sono stati analizzati dei Box Plot. Essendo 56 Box Plot difficili da analizzare, è stata calcolata per ciascuna feature la differenza tra le mediane delle due classi, normalizzata per la deviazione standard.

$$s_j = \frac{|\text{med}_{\text{spam}}(x_j) - \text{med}_{\text{non-spam}}(x_j)|}{\sigma_j + \epsilon}$$

I risultati ottenuti, presenti nella Tabella 3.1, indicano chiaramente che le feature più discriminanti sono: word_freq_your, word_freq_you, word_freq_all, word_freq_will, word_freq_our e char_freq_! .

Feature	Separation
word_freq_your	0.990998
word_freq_you	0.940590
word_freq_all	0.595069
word_freq_will	0.499014
word_freq_our	0.431219
char_freq_!	0.405801
char_freq_\$	0.325359
capital_run_length_total	0.230891
word_freq_free	0.169534
capital_run_length_longest	0.143670
capital_run_length_average	0.055595
char_freq_(	0.001849
<i>Tutte le altre 45 feature</i>	0.000000

Tabella 3.1: Valori di separazione delle caratteristiche

3.3 Analisi delle relazioni tra le feature più discriminanti

Per capire se tra le feature più discriminanti ci sia una relazione lineare o non lineare sono stati analizzati dei Pair Plot mostrati nella Figura 3.2.

Si nota che la sovrapposizione parziale tra le classi suggerisce che la classificazione richiede l'utilizzo di più feature e che sono presenti delle relazioni non lineari. Per tale motivo, per la matrice di correlazione non verrà utilizzato il coefficiente di Pearson.




Figura 3.2: Pair Plot tra le variabili più discriminanti

3.4 Matrice di correlazione di Spearman

È stato utilizzato il coefficiente di Spearman in quanto:

1. **Grande numero di 0 all'interno delle feature:** l'indice di Spearman lavora sui ranghi anziché sui valori assoluti. Di conseguenza ai valori pari a 0 vengono assegnati i ranghi più bassi, mentre ai valori non nulli vengono assegnati ranghi via via più elevati in base alla loro grandezza. Infine, il coefficiente viene calcolato applicando la formula di Pearson sull'intera distribuzione dei ranghi ottenuti.
2. **Presenza di outliers:** dato che nel dataset è presente una forte variazione dei dati (da valori molto grandi a estremamente piccoli), Spearman risulta più robusto rispetto a Pearson (che è più sensibile alla distanza tra i dati).
3. **Relazioni non lineari:** il coefficiente di Pearson valuta esclusivamente la presenza di una relazione lineare. L'indice di Spearman, invece, converte i dati in ranghi per misurare la monotonicità della relazione; in questo modo, è in grado di rilevare se due variabili si muovono nella stessa direzione in modo consistente.

Il grafico in Figura 3.3 evidenzia come diverse feature siano correlate al target, sempre con il coefficiente di Spearman.




Figura 3.3: Matrice di correlazione tra le feature e il target




Figura 3.4: Matrice di correlazione tra le feature




Figura 3.5: Matrice di correlazione tra le feature - blocco centrale




Figura 3.6: Matrice di correlazione tra le feature - blocco angolare

Nella Figura 3.4 viene rappresentata la matrice di correlazione completa. Come si nota, ci sono due aree di maggiore interesse, dove sono presenti le variabili più correlate. In Figura 3.5 e 3.6 vengono mostrate queste aree da vicino per una migliore comprensione. Si può notare una forte correlazione tra le feature:

- *word_freq_857* e *word_freq_415*, correlazione $r = 0.96$
- *word_freq_hp* e *word_freq_hpl* con correlazione $r = 0.76$
- *capital_run_length_average* e *capital_run_length_longest*, con correlazione $r = 0.86$
- *capital_run_length_longest* e *capital_run_length_total*, con correlazione $r = 0.86$

Per decidere chi tenere, andiamo a vedere chi ha l'associazione di Spearman più alta rispetto al target (*Class*):

- tra *word_freq_857*: $r_{\text{target}} = -0.170$ e *word_freq_415*: $r_{\text{target}} = -0.158$
- tra *word_freq_hp*: $r_{\text{target}} = -0.400$ e *word_freq_hpl*: $r_{\text{target}} = -0.342$
- tra *capital_run_length_average*: $r_{\text{target}} = 0.488$ e *capital_run_length_longest*: $r_{\text{target}} = 0.515$,
- tra *capital_run_length_longest*: $r_{\text{target}} = 0.515$ e *capital_run_length_total*: $r_{\text{target}} = 0.444$,

In questo caso le feature che rimuoveremo nella fase di Preprocessing saranno:

- *word_freq_415*
- *word_freq_hpl*
- *capital_run_length_average*
- *capital_run_length_total*

3.5 Analisi del P-value

Successivamente è stato valutato il p-value con Spearman, il quale misura la probabilità che la correlazione osservata sia casuale. Abbiamo utilizzato la soglia standard di significatività $\alpha = 0.05$ per individuare le variabili che dovranno essere rimosse dal dataset perchè non hanno un legame statisticamente attendibile con il target.

Nella Tabella 3.2 vengono rappresentati i risultati. Le feature con valore p superiore ad α verranno rimosse nella fase di Preprocessing.

Feature	Spearman r	p Spearman
word_freq_parts	-0.003	0.8640
word_freq_table	-0.023	0.1242
word_freq_direct	0.028	0.0564
char_freq_(	-0.033	0.0269
char_freq_;	-0.057	0.0001
<i>Tutte le altre 52 feature</i>	$[-0.400, 0.598]$	0.0000

Tabella 3.2: Calcolo del P-value

Rilevare queste relazioni, sia tramite la matrice di correlazione, sia tramite il p-value, è fondamentale. La presenza di variabili altamente correlate introduce nel modello informazioni ridondanti, che possono compromettere la stabilità e l'efficienza di algoritmi sensibili alla dimensionalità come la SVM.

Capitolo 4

Descrizione dei Modelli utilizzati

Al fine di soddisfare i requisiti del progetto, sono stati implementati e confrontati **due modelli di Machine Learning supervisionati**, preceduti dalla definizione di un modello di baseline.

4.1 Modello Baseline

Prima di valutare gli algoritmi predittivi, è stato introdotto un modello "dummy". Questo modello non apprende i dati, ma predice sempre la classe maggioritaria (0) per qualsiasi istanza del test, facendo uso della funzione `np.zeros()`. Esso stabilisce la soglia minima di accuratezza.

4.2 Decision tree

Il primo modello selezionato è il **Decision Tree**, un modello di classificazione basato su una struttura gerarchica di decisioni, in cui lo spazio delle istanze viene suddiviso iterativamente tramite regole basate sugli attributi.

I vantaggi offerti da questo modello sono:

- Seleziona implicitamente le variabili più informative ad ogni split, ignorando quelle non rilevanti.
- Non lavorando sulle distanze metriche, non richiede la standardizzazione dei dati.

L'ottimizzazione dell'albero si concentra sul controllo della sua complessità tramite il parametro `max_depth`, fondamentale per prevenire fenomeni di **overfitting** (albero troppo profondo che memorizza il rumore del training set) o **underfitting** (albero troppo superficiale). Il criterio di scissione utilizzato è l'indice di impurità di Gini (G):

$$G = 1 - \sum_{i=1}^k p_i^2$$

Il valore minimo ($G = 0$) indica la massima purezza di un nodo (tutti gli elementi appartengono a una sola classe). Il parametro `min_samples_split` è mantenuto al valore di default pari a 2.

4.3 SVM

Il secondo modello è la **Support Vector Machine**, un algoritmo geometrico che mira a individuare l'iperpiano di separazione ottimale a **massimo margine** tra le classi. A differenza del Decision Tree, la SVM è altamente sensibile alla scala delle feature, quindi richiede dati standardizzati per evitare che variabili con intervalli numerici più ampi dominino la funzione di costo. In questo progetto si è scelto di adottare un **Kernel Lineare**, in quanto cerca una linea retta, nel nostro caso un iperpiano perchè abbiamo più dimensioni, che separa al meglio i punti di Not Spam e Spam.

L'iperparametro fondamentale è la costante di regolarizzazione C , che controlla il trade-off tra l'ampiezza del margine e la tolleranza agli errori di classificazione del training set.

Un valore di C basso genera un margine più ampio e tollerante, aumentando il rischio di underfitting. Al contrario, un valore di C elevato impone un vincolo più rigido, aumentando l'overfitting.

Capitolo 5

Descrizione della campagna sperimentale

Nel seguente capitolo, è stata descritta la metodologia per l'addestramento dei modelli, la strategia di validazione e la selezione dei migliori parametri tramite test empirici.

La validazione dei modelli è stata condotta in due fasi:

1. **Hold-out Validation:** Divisione dell'intero dataset in due macro set: l'80% dedicato al training set, il restante 20% dedicato al test set. Un dettaglio importante risiede nella **stratificazione dei set**, cioè che ciascun macro set è stato suddiviso tale da avere la stessa percentuale di casi di "not spam" e di "spam" pari alla distribuzione dell'intero dataset, in altre parole, ciascun macro set si compone del 61% di casi "not spam" e 39% di casi "spam".
2. **5-Fold Cross-Validation:** La scelta degli iperparametri è stata condotta sulla porzione di training mediante una validazione incrociata a 5 fold ($cv = 5$). Questa tecnica previene il data leakage e garantisce che la valutazione delle metriche sia stabile e indipendente da split fortuiti.

La preparazione dei dati è stata differenziata in base alla natura matematica dei modelli: il Decision Tree è stato addestrato sul dataset originale (X_{train}), sfruttando le sue capacità native di feature selection implicita; la SVM è stata invece allenata con X_{train_scaled} , un set senza le feature ridondanti e normalizzato tramite *StandardScaler*.

Per la selezione dei migliori iperparametri, GridSearchCV è stato configurato con i seguenti parametri comuni a entrambi i modelli:

- $n_jobs = -1$: per ottimizzare i tempi di calcolo; Tutte le ricerche sono state parallelizzate sfruttando la totalità dei core.
- $scoring = 'accuracy'$: la metrica accuracy ha guidato la scelta per il miglior parametro.
- $class_weight = balanced$: per compensare il leggero sbilanciamento delle classi, così rendere il modello più sensibile alla classe minoritaria.

5.1 Albero Decisionale

Attraverso la classe *GridSearchCV*, è stata testata una griglia di valori per max_depth compresi nell'intervallo $[1, 20]$. L'algoritmo ha identificato come configurazione ottimale una profondità $max_depth = 18$, registrando un'accuratezza media in Cross-Validation pari a circa il 92.55%. Data l'elevata profondità raggiunta dall'albero ottimizzato, si è scelto di ometterne la visualizzazione grafica (tramite *plot_tree*), poiché la struttura decisionale a 18 livelli risulterebbe eccessivamente densa e di difficile interpretazione visiva.

5.2 Support Vector Machine

La SVM cerca l'iperpiano che massimizza la distanza tra esso e i punti più vicini di ciascuna classe. Per questo motivo, la standardizzazione dei dati ha un ruolo molto importante. Senza di essa, feature di scala ridotta potrebbero venire ignorate, anche se predittivamente importanti. A tal fine è stata utilizzata la classe *StandardScaler*.

Attraverso la classe *GridSearchCV*, è stata testata una griglia di valori per C esplorando una scala logaritmica con i valori 0.01, 0.1, 1, 10, 100.

È stato inoltre impostato il parametro *probability = True*, necessario per ottenere le stime di probabilità delle classi, indispensabili per il calcolo della curva di ROC e dell'AUC nella fase di valutazione successiva. È importante sottolineare che questa opzione introduce un costo computazionale aggiuntivo, poiché scikit-learn esegue una Cross-Validation interna per calibrare le probabilità tramite il metodo di *Platt Scaling*.

Dall'analisi, l'algoritmo ha trovato come configurazione ottimale il valore $C = 10$, registrando un'accuratezza media in Cross-Validation pari a circa il 93.26%.

Capitolo 6

Analisi dei risultati

6.1 Definizione delle metriche

In questo capitolo vengono presentati e confrontati i risultati ottenuti dai due modelli. Per valutare puntualmente le performance dei classificatori su ciascuna delle classi, si è fatto riferimento alle seguenti metriche statistiche:

- **Accuracy (Accuratezza):** indica la proporzione di previsioni corrette fatte dal modello sul totale delle previsioni.

$$\text{Accuracy} = \frac{\text{Previsioni Corrette}}{\text{Totale Previsioni}}$$

- **Precision (Precisione):** misura quante delle previsioni positive fatte dal modello sono effettivamente corrette.

$$\text{Precision} = \frac{TP}{TP + FP}$$

Dove TP = True Positive (Vero Positivo) e FP = False Positive (Falso Positivo).

- **Recall (Sensibilità o Richiamo):** misura quanti dei casi positivi reali sono stati correttamente identificati dal modello.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Dove FN = False Negative (Falso Negativo).

- **F1-Score:** è la media armonica della Precision e della Recall. Un punteggio alto significa che il modello ha ottenuto ottime prestazioni bilanciando entrambe le metriche. Il suo intervallo di valori è $[0, 1]$.

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

6.2 Risultati dei modelli

6.2.1 Modello di Baseline

Come mostrato nella Tabella 6.1, il modello presenta una *accuracy* del 61%. Questo valore dipende solo dallo sbilanciamento del dataset. Come si vede dalla Matrice di Confusione rappresentata in Figura 6.1, i TN sono 0, quindi nessuna email di spam viene correttamente identificata. L'obiettivo dei modelli di Machine Learning successivi (Decision Tree e SVM) non sarà semplicemente superare l'accuratezza, ma dimostrare la capacità di massimizzare la *Recall* e minimizzare i FN.




Figura 6.1: Matrice di Confusione del modello Baseline

Classe / Metrica	Precision	Recall	F1-Score	Support
0 (Not Spam)	0.61	1.00	0.75	558
1 (Spam)	0.00	0.00	0.00	363
Accuracy			0.61	921
Macro Avg	0.30	0.50	0.38	921
Weighted Avg	0.37	0.61	0.46	921

Tabella 6.1: Classification Report del modello Baseline sul set di test.

6.2.2 Decision Tree

La Figura 6.2 mostra la matrice di confusione del modello Decision Tree con il dataset completo. Il modello è in grado di identificare correttamente 522 email legittime su 558 e 318 email di spam su 363.




Figura 6.2: Matrice di Confusione del Decision Tree

Come si può notare nella Tabella 6.2, il Decision Tree mostra ottime capacità predittive, raggiungendo un'accuratezza del 91% sul test set. L'F1-score risulta bilanciato per entrambe le classi, confermando che il modello è in grado di gestire adeguatamente lo sbilanciamento originale del dataset.

Classe / Metrica	Precision	Recall	F1-Score	Support
0 (Not Spam)	0.92	0.94	0.93	558
1 (Spam)	0.90	0.88	0.89	363
Accuracy			0.91	921
Macro Avg	0.91	0.91	0.91	921
Weighted Avg	0.91	0.91	0.91	921

Tabella 6.2: Classification Report del Decision Tree sul set di test.

6.2.3 Support Vector Machine (SVM)

La Figura 6.3 mostra la matrice di confusione del modello SVM con il dataset ridotto e standardizzato. Il modello è in grado di identificare correttamente 524 email legittime su 558 e 328 email di spam su 363.




Figura 6.3: Matrice di Confusione della SVM

Dalla Tabella 6.3 si può notare che l'accuratezza complessiva sia 93%, maggiore del 2% rispetto al Decision Tree. L'F1-score risulta essere bilanciato per entrambe le classi e ottiene dei risultati migliori rispetto al Decision Tree.

Classe / Metrica	Precision	Recall	F1-Score	Support
0 (Not Spam)	0.94	0.94	0.94	558
1 (Spam)	0.91	0.90	0.90	363
Accuracy			0.93	921
Macro Avg	0.92	0.92	0.92	921
Weighted Avg	0.93	0.93	0.93	921

Tabella 6.3: Classification Report del SVM sul set di test.

6.3 Curva di ROC

La Curva di ROC permette di mostrare il tradeoff tra "trovare più email Spam" e "fare meno errori sulle email legittime" al variare della soglia. L'AUC, invece, sintetizza il tradeoff in un numero unico. Più questo valore è vicino a 1, più il modello è migliore.




Figura 6.4: Curva di ROC dei due modelli supervisionati

Dalla Figura 6.4, il confronto tramite curva di ROC evidenzia ottime performance per entrambi i modelli. Il Decision Tree ha ottenuto un punteggio $AUC = 0.90$, mentre la SVM ha ottenuto un punteggio $AUC = 0.97$, affermandosi in questo modo un classificatore quasi perfetto e affidabile.

6.4 Tempo di training

Sono stati poi registrati i tempi di training dei due modelli, riportando un risultato circa pari a **0.1 secondi** per il Decision Tree e circa **13 secondi** per il SVM. Il Decision Tree quindi è nettamente più rapido rispetto al SVM. Questo perchè l'algoritmo del Decision Tree è basato sulle soglie, vengono infatti eseguiti gli split basandosi su esse. Il tempo di esecuzione è pari a $O(m \cdot n \log n)$, dove n è il numero di campioni, mentre m è il numero di feature. L'algoritmo di SVM, invece, punta ad individuare l'iperpiano di margine massimo con un tempo di esecuzione compreso tra $O(n^2)$ e $O(n^3)$.

A tale differenza intrinseca tra i due algoritmi si aggiunge il costo computazionale introdotto dal parametro `probability=True` (Sezione 5.2), contribuendo ulteriormente al tempo di training più elevato registrato per la SVM.

Su un dataset di dimensioni contenute come Spambase (4600 righe) questa differenza non è limitante, ma diventerebbe un fattore rilevante nella scelta del modello su dataset più grandi o in scenari che richiedono un ri-allenamento frequente.

6.5 Confronto col modello baseline

In questa sezione si mettono a confronto i risultati del modello di baseline con i due modelli addestrati.

Modello	Accuracy	Precision	Recall	F1-Score
Baseline	0.61	0.37	0.61	0.46
Decision Tree	0.91	0.91	0.91	0.91
SVM	0.93	0.93	0.93	0.93

Tabella 6.4: Confronto delle metriche principali (Weighted Avg) tra tutti i modelli sul set di test.

Come si può osservare dalla Tabella 6.4, i due modelli risultano nettamente superiori rispetto al modello baseline. Quest'ultimo presenta una Precision pari quasi ad un terzo rispetto agli altri due modelli, un'Accuracy e una Recall inferiori di circa 0.30 punti rispetto ad entrambi. Questo significa che il baseline, prevedendo sempre e solo la classe di maggioranza, riesce a classificare correttamente le email legittime ma fallisce completamente nell'identificare quelle di spam, con una Recall pari a 0.00 per la classe 1.

I due modelli addestrati superano questo limite in modo significativo, dimostrando che le feature del dataset contengono informazioni realmente discriminanti per distinguere le email legittime con quelle di spam. In particolare, la SVM si conferma il modello più affidabile, raggiungendo una Recall di 0.90 sulla classe 1.

Capitolo 7

Conclusioni

Il seguente progetto ha analizzato l'andamento di due modelli di Machine Learning.

Il modello che ha generato risultati migliori per questo dominio è sicuramente la **SVM**, grazie a un'accurata fase di preprocessing e la standardizzazione dei dati, tutte le 4 metriche hanno restituito valori molto alti.

Il Decision Tree, seppur abbia restituito delle metriche leggermente minori rispetto alla SVM, si è dimostrato un modello molto performante senza l'utilizzo di standardizzazione o riduzione del dataset. In uno scenario in cui si tiene traccia dei tempi di computazione, i Decision Tree offrono tempi di esecuzione molto più rapidi della SVM.